PROYECTO ETL – WORLD DEVELOPMENT INDICATORS

Modelado Dimensional y Análisis de Indicadores Globales

Alineado al ODS 3 – Salud y Bienestar

RODRIGO ANDRÉS GÓMEZ LÓPEZ. Código: 2247014

BRAYAN GUTIERREZ

ETL

Presentado a:

MSC. DAVID

UNIVERSIDAD AUTÓNOMA DE OCCIDENTE

INGENIERÍA DE DATOS E INTELIGENCIA ARTIFICIAL

SANTIAGO DE CALI

2026

Contenido

1. INTRODUCCIÓN 3
2. REQUIREMENTS GATHERING 4
2.1 OBJETIVO GENERAL 4
2.2 PREGUNTAS DE NEGOCIO 4
2.3 CRITERIOS DE EVALUACIÓN 4
3. DATA SOURCE EVALUATION 5
4.1 ARQUITECTURA GENERAL 7
4.2 CAPAS 8
5. MODELO DE DATOS 9
5.1 MODELO RELACIONAL LIMPIO 9
5.3 VALIDACIÓN DE INTEGRIDAD 11
6. DATA MIGRATION 13
7. EXPLORATORY DATA ANALYSIS (EDA) 15
7.1 VALORES NULOS 15
7.2 TOP 10 INDICADORES CON MÁS DATOS 15
7.3 TENDENCIA GLOBAL – ESPERANZA DE VIDA 15
7.4 COLOMBIA VS MUNDO 16
7.5 MUJERES VS HOMBRES 16
8. CONSULTAS OLAP DESDE EL MODELO ESTRELLA 18
9. VISUALIZACIONES 19
10. SDG ALIGNMENT 21
11. GITHUB REPOSITORY 22
12. CONCLUSIONES 23
13. STACK TECNOLÓGICO 24

1. INTRODUCCIÓN

Este proyecto consiste en el diseño e implementación de un proceso completo de ETL (Extract, Transform, Load) utilizando datos abiertos del Banco Mundial (World Development Indicators – WDI).

El objetivo no fue únicamente generar visualizaciones, sino estructurar los datos siguiendo principios reales de Data Engineering, incluyendo:

- Migración desde CSV hacia base de datos relacional (MySQL)
- Limpieza y transformación de datos
- Diseño de modelo dimensional (Star Schema)
- Construcción de tabla de hechos y dimensiones
- Consultas OLAP reales
- Visualizaciones alimentadas desde la base de datos

El proyecto se encuentra alineado con el ODS 3: Salud y Bienestar, utilizando como indicador principal la esperanza de vida al nacer, métrica clave para evaluar el desarrollo humano y condiciones de salud global.

2. REQUIREMENTS GATHERING

2.1 OBJETIVO GENERAL

Construir un pipeline ETL funcional que permita analizar indicadores globales del Banco Mundial mediante un modelo dimensional optimizado para análisis.

2.2 PREGUNTAS DE NEGOCIO

1. ¿Cómo ha evolucionado la esperanza de vida promedio mundial desde 1960?
2. ¿Cómo se compara Colombia frente al promedio global?
3. ¿Existe diferencia significativa entre hombres y mujeres?
4. ¿Qué indicadores tienen mayor cantidad de registros disponibles?
5. ¿Qué tan completa es la información reportada?

2.3 CRITERIOS DE EVALUACIÓN

- Migración exitosa a base de datos relacional
- Diseño correcto de modelo estrella
- Integridad referencial sin valores nulos en llaves
- Visualizaciones generadas desde consultas SQL
- Arquitectura documentada y justificada
- Alineación clara con un ODS

3. DATA SOURCE EVALUATION

Dataset Seleccionado: World Development Indicators (WDI) – Banco Mundial

Justificación del dataset

Enlace: https://datacatalog.worldbank.org/search/dataset/0037712/world-development-indicators

Dataset seleccionado: *World Development Indicators (WDI) – Bulk Download (CSV)* del Banco Mundial.

¿Por qué es adecuado para el proyecto ETL (ODS 4: Educación de Calidad)?

- Fuente oficial y confiable: proviene del Banco Mundial, una entidad reconocida que consolida indicadores globales a partir de fuentes oficiales (ministerios, UNESCO, etc.).
- Cobertura global: incluye prácticamente todos los países/territorios, lo que permite análisis comparativos (por región, ingreso, país) y cumple bien con un enfoque ODS.
- Cobertura temporal amplia: tiene series históricas por años (décadas), ideal para análisis de tendencias y evolución (por ejemplo 2000–2022).
- Formato apto para ETL real: viene en un CSV "bulk" con estructura consistente y archivos complementarios de metadatos (series, países, notas). Esto permite:
    - construir un modelo dimensional (OLAP) con dimensiones como país, indicador, tiempo,
    - aplicar transformaciones típicas (reshape wide→long, limpieza, filtrado de años, control de nulos),
    - documentar extracción, transformación y carga de forma estándar.
- Alineación directa con ODS 4: contiene múltiples indicadores educativos (matrícula bruta, finalización, fuera del sistema escolar, gasto en educación, alfabetización, etc.), lo que facilita crear preguntas de negocio/analíticas coherentes con "Educación de Calidad".

Fuente oficial y confiable

Datos históricos desde 1960

Cobertura global

Gran volumen (>10.000 filas, >10 variables)

Estructura adecuada para modelado dimensional

Calidad del Dataset

Se detectaron valores nulos (455.494 en dataset original expandido)

Se filtraron registros sin valor para evitar inconsistencias

Se normalizó estructura tipo wide a long

Se garantizó integridad en tabla de hechos

4. ARQUITECTURA ETL PROPUESTA

4.1 ARQUITECTURA GENERAL

CSV (WDI)

↓

Python (Pandas)

↓

MySQL (Staging - wdi_raw)

↓

Transformación (wdi_clean)

↓

Modelo Estrella (Data Warehouse)

↓

Consultas SQL (OLAP)

↓

Visualizaciones (Matplotlib)

4.2 CAPAS

Capa	Tecnología	Función
Ingesta	Python + Pandas	Leer CSV
Staging	MySQL	Almacenar datos crudos
Transformación	Pandas + SQL	Limpieza y normalización
Data Warehouse	MySQL	Modelo estrella
Análisis	SQL	Consultas OLAP
Visualización	Matplotlib	Gráficos finales
Versionamiento	Git + GitHub	Control de versiones

5. MODELO DE DATOS

5.1 MODELO RELACIONAL LIMPIO

Después de la transformación, se obtuvo la tabla:

wdi_clean

- Country Code
- Country Name
- Indicator Code
- Indicator Name
- Year
- Value

PK lógica: (Country Code, Indicator Code, Year)

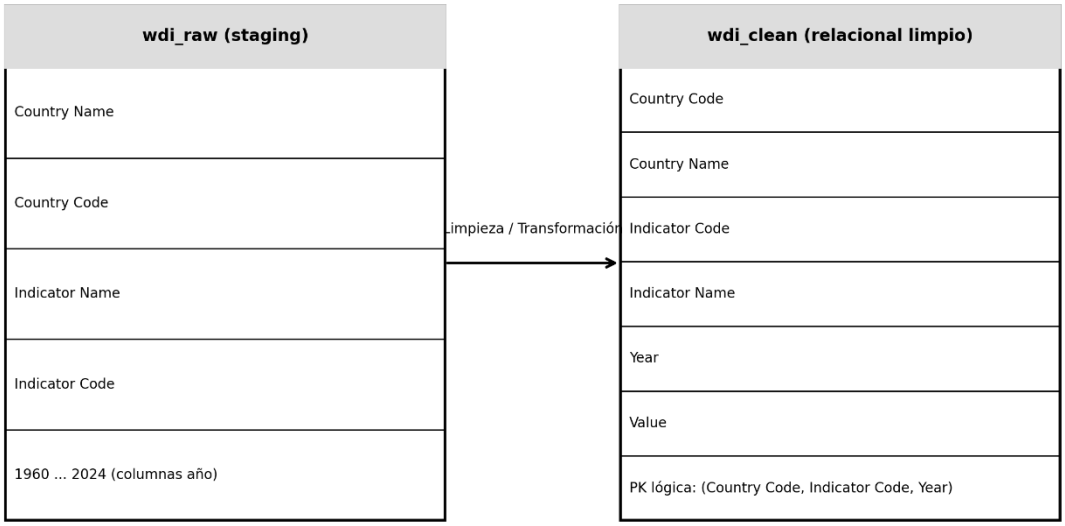

En este driagrama se puede ver los siguiente:

- `wdi_raw` representa el dato casi tal cual llega del CSV (muchas columnas por año).

- `wdi_clean` es el resultado “arreglado” para análisis: dejamos los años en una sola columna `Year` y el valor en `Value`.

- La clave lógica (Country Code, Indicator Code, Year) evita duplicados por combinación país–indicador–año.

- Este paso es clave porque prepara la info para construir un modelo dimensional sin sufrir con 60+ columnas de años.

5.2 Modelo Dimensional – Star Schema

Se diseñó un modelo estrella para optimizar análisis.

Dimensiones

dim_country

- country_key (PK)
- country_code
- country_name

dim_indicator

- indicator_key (PK)
- indicator_code
- indicator_name

dim_date

- date_key (PK)
- Year

Tabla de Hechos

fact_wdi

- country_key (FK)
- indicator_key (FK)
- date_key (FK)

- Value (medida)

Total registros: 194.506 filas

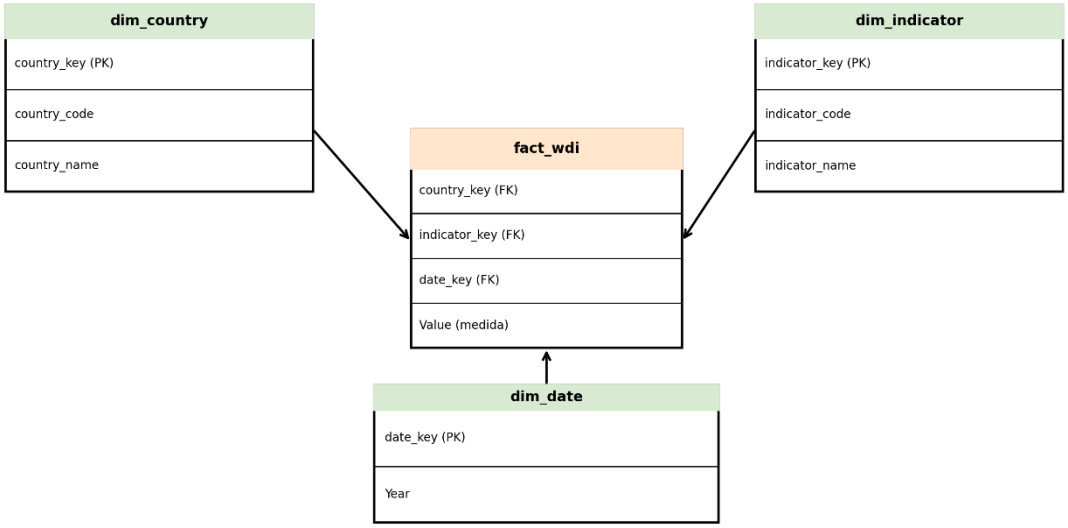

El diagrama en estrella muestra lo siguiente:

- fact_wdies la tabla central: aquí está la “medida” (`Value`) y las llaves.

- dim_country describe el país (nombre, código).

- dim_indicator describe el indicador (qué estamos midiendo).

- dim_date organiza el tiempo (año).

Lo bueno de esto es que ahora puedo hacer consultas tipo:

- “Promedio de esperanza de vida por año”

- “Comparar Colombia vs mundo”

- “Top indicadores con más datos”

solo haciendo JOINs simples y rápidos desde la tabla de hechos hacia las dimensiones.

5.3 VALIDACIÓN DE INTEGRIDAD

Consulta de chequeo:

null_country_key = 0

null_indicator_key = 0

null_date_key = 0

null_value = 0

Conclusión:

La integridad referencial se cumple correctamente.

6. DATA MIGRATION

La migración se realizó en tres fases:

1. CSV → wdi_raw (staging)
2. wdi_raw → wdi_clean (normalización)
3. wdi_clean → modelo estrella

Se utilizó:

```
df.to_sql(..., engine)
```

La base utilizada fue:

MySQL – Base: wdi_etl_db

paso 5. Creo base de datos en mysql

```
1 • CREATE DATABASE IF NOT EXISTS wdi_etl_db
2     DEFAULT CHARACTER SET utf8mb4
3     DEFAULT COLLATE utf8mb4_unicode_ci;
```

CREATE DATABASE IF NOT EXISTS wdi_etl_db

DEFAULT CHARACTER SET utf8mb4

DEFAULT COLLATE utf8mb4_unicode_ci;

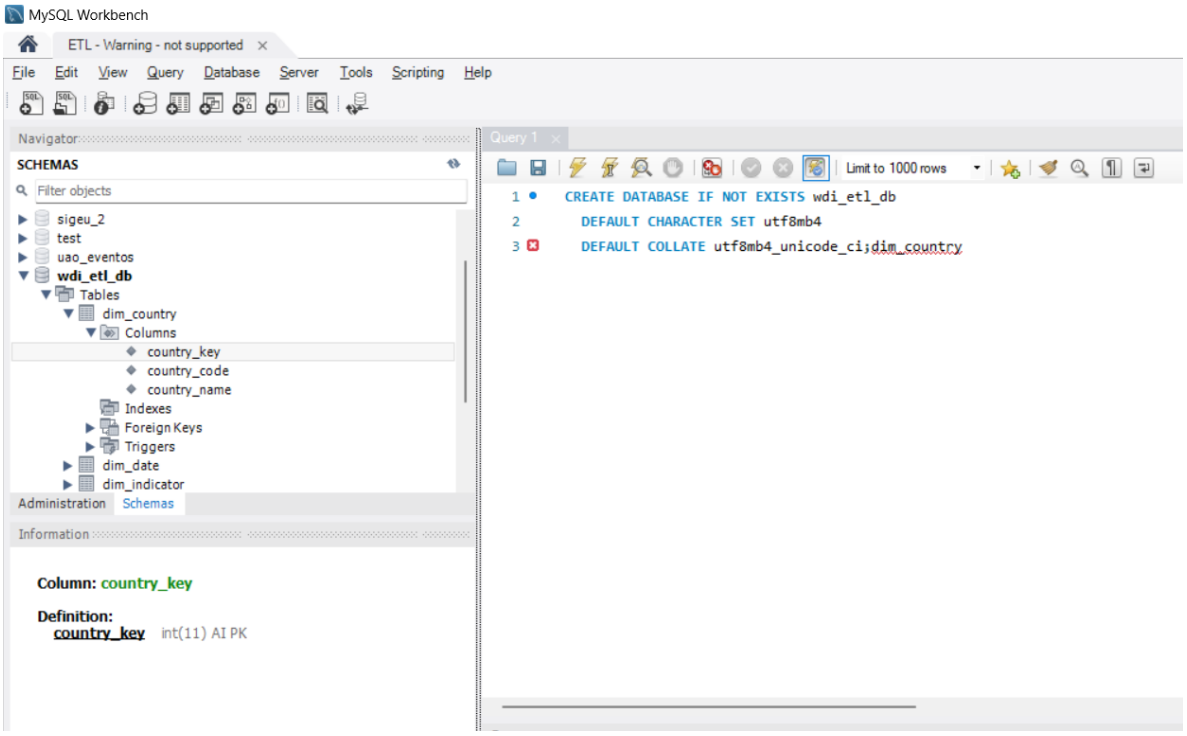
MySQL Workbench
ETL - Warning - not supported
File Edit View Query Database Server Tools Scripting Help
Navigator
SCHEMAS
Filter objects
sigeu_2
test
uao_eventos
wdi_etl_db
Tables
dim_country
Columns
country_key
country_code
country_name
Indexes
Foreign Keys
Triggers
dim_date
dim_indicator
Administration Schemas
Information
Column: country_key
Definition:
country_key int(11) AI PK
Query 1
Limit to 1000 rows
1 CREATE DATABASE IF NOT EXISTS wdi_etl_db
2 DEFAULT CHARACTER SET utf8mb4
3 DEFAULT COLLATE utf8mb4_unicode_ci;dim_country

7. EXPLORATORY DATA ANALYSIS (EDA)

7.1 VALORES NULOS

Se identificaron más de 455.000 valores nulos en dataset expandido. Se decidió excluir registros sin valor para la tabla de hechos.

7.2 TOP 10 INDICADORES CON MÁS DATOS

Se realizó consulta OLAP:

Resultado:

- Age dependency ratio (455 registros)
- Life expectancy (448 registros)
- Fertility rate (448 registros)
- Birth rate (448 registros)

Conclusión:
Los indicadores demográficos tienen alta disponibilidad histórica.

7.3 TENDENCIA GLOBAL – ESPERANZA DE VIDA

Promedio Mundial:

1960 : ~49 años
2023 : ~72 años

Se observa crecimiento sostenido con leve caída en 2020–2021 (posible efecto pandemia).

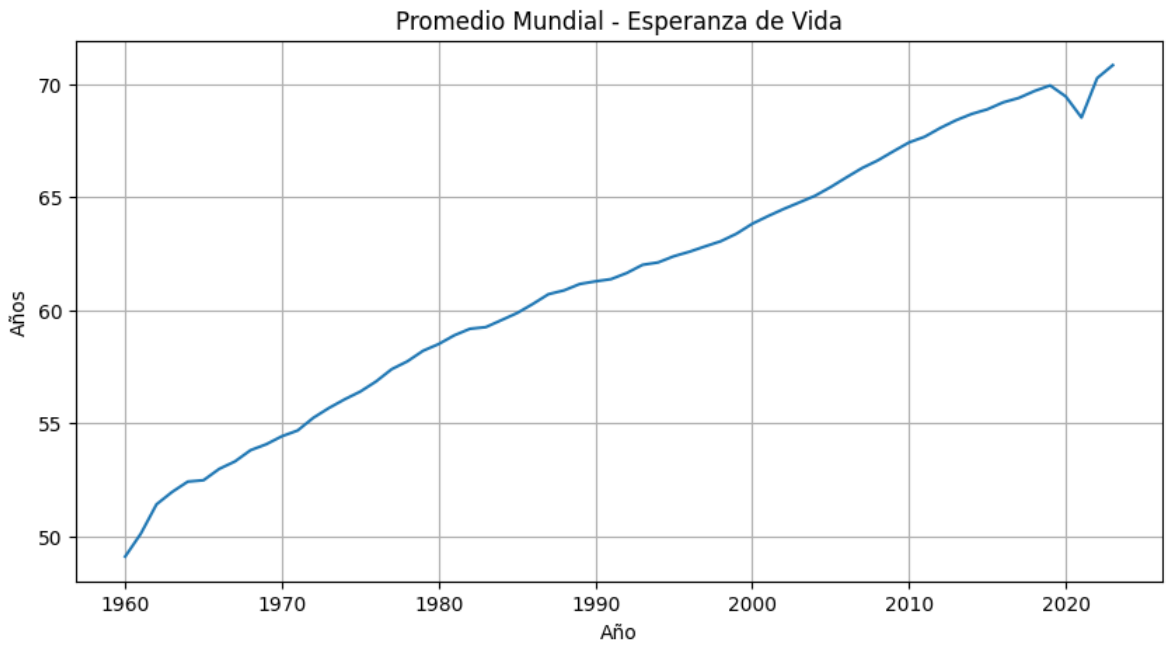

7.4 COLOMBIA VS MUNDO

Colombia sigue tendencia similar al promedio mundial. En décadas recientes se acerca significativamente al promedio global.

7.5 MUJERES VS HOMBRES

- Mujeres presentan mayor esperanza de vida en todos los años.
- Diferencia promedio: 4–6 años.
- Tendencia creciente en ambos casos.

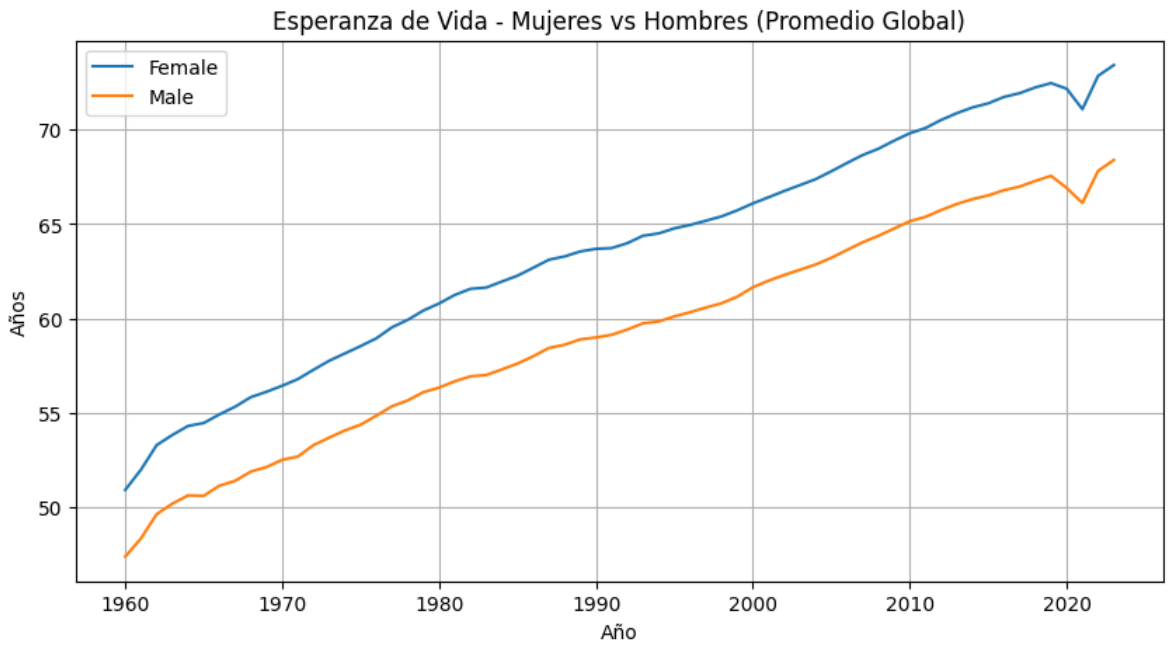

Visualización 3 — Colombia vs Promedio Mundial

Esta comparación es de las mejor porque contextualiza.

Aquí tomamos el mismo indicador (esperanza de vida total) y comparar:

- Colombia

- Promedio mundial

Así no solo digo “sube”, sino “¿Colombia está arriba o abajo del promedio mundial?”

8. CONSULTAS OLAP DESDE EL MODELO ESTRELLA

Se probó el modelo con JOIN completo:

```
SELECT country_name, indicator_name, Year, Value
FROM fact_wdi f
JOIN dim_country c ON f.country_key = c.country_key
JOIN dim_indicator i ON f.indicator_key = i.indicator_key
JOIN dim_date d ON f.date_key = d.date_key;
```

Resultado exitoso: confirma correcto diseño dimensional.

9. VISUALIZACIONES

Todas las visualizaciones fueron alimentadas desde consultas SQL.

Se desarrollaron:

1. Tendencia mundial esperanza de vida
2. Colombia vs Mundo
3. Mujeres vs Hombres
4. Top indicadores por volumen

Cada visual responde directamente a preguntas de negocio definidas al inicio.

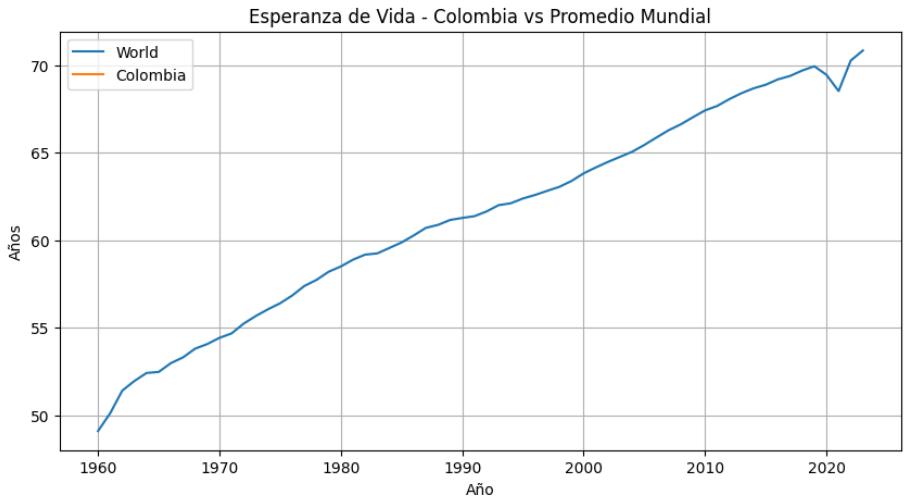

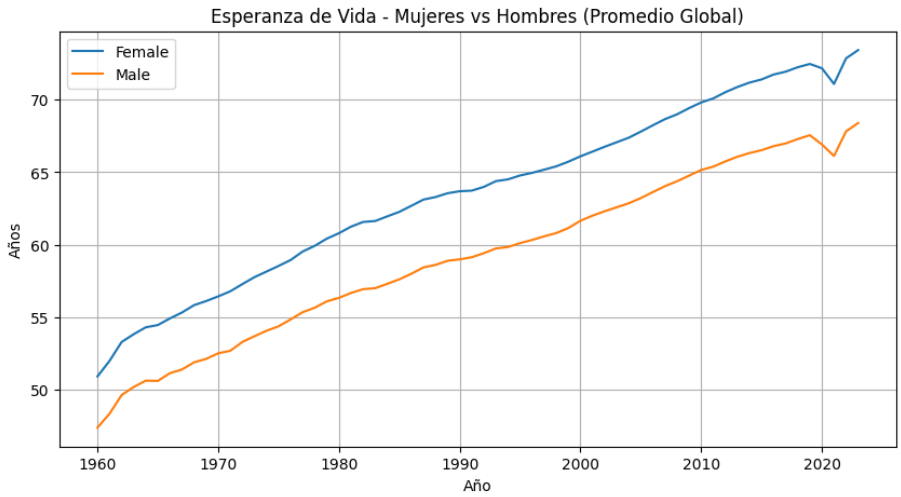

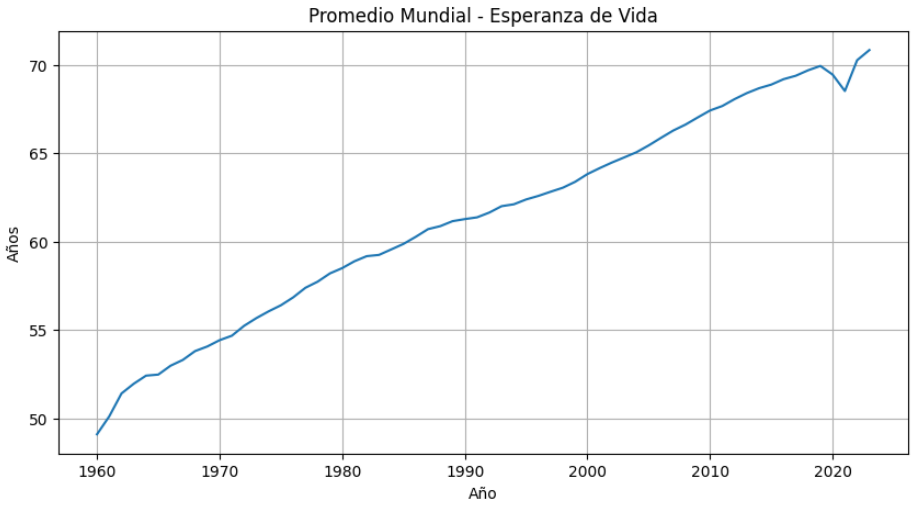
Promedio Mundial - Esperanza de Vida
Años
Año
70
65
60
55
50
1960
1970
1980
1990
2000
2010
2020

10. SDG ALIGNMENT

Este proyecto se alinea con:

ODS 3 – Salud y Bienestar

La esperanza de vida al nacer es uno de los indicadores más representativos del estado sanitario de un país.

- Comparación regional (Colombia)

11. GITHUB REPOSITORY

ENLACE: https://github.com/aglsystems-ragl/PROYECTO_WDI_ETL

El repositorio incluye:

```
PROYECTO_WDI_ETL/
│
├── data/
│   └── raw/
│       └── WDI_10k_AGL.csv
│
├── notebooks/
│   └── ETL_WDI.ipynb
│
├── docs/
│   ├── modelo_relacional.png
│   ├── modelo_estrella.png
│
├── README.md
└── .gitignore
```

12. CONCLUSIONES

1. Se construyó exitosamente un pipeline ETL funcional.
2. Se diseñó e implementó un modelo estrella correcto.
3. Se garantizó integridad referencial.
4. Se realizaron consultas OLAP reales.
5. Se generaron visualizaciones coherentes con los objetivos.
6. Se logró alineación clara con ODS 3.
7. El proyecto simula flujo real de Data Engineering.

13. STACK TECNOLÓGICO

Python

Pandas

SQLAlchemy

MySQL

Jupyter Notebook

Matplotlib

Git / GitHub